

Clasificación automática de razas de perros utilizando un modelo de AI

UPC

1 de febrero de 2024

Presentado por:

- Paulo Sergio Costa Mondragón u201912806

Resumen

En la actualidad el campo de la inteligencia artificial y el procesamiento de imágenes está avanzando a una velocidad exponencial. Cosas como reconocimiento facial, reconocimiento de tumores en radiografías y demás son más enfocadas al ser humano pero, ¿cómo podemos ir más allá y aplicar todo esto a las mascotas? Incontables son los casos de personas que han llegado a ver un perro y no han tenido manera de saber de que raza son a menos que pregunten al dueño o alguien por casualidad sepa que raza es. Otro punto en el cual podríamos enfocar esta investigación es en la clasificación de razas de perros para cuando se extravían. El reconocimiento de raza es un pequeño paso para luego identificar más cualidades como altura, peso, manchas reconocibles, etc. Ante esta necesidad y/o problema, hemos decidido aplicar inteligencia artificial para poder analizar y estudiar un dataset de perros e identificar de qué raza es. Utilizaremos Convolutional Neural Network(CNN) ya que es un modelo usado en casos de clasificación y reconocimiento de imágenes.

palabras clave— *Raza de perro, inteligencia artificial, reconocimiento de imágenes, Convolutional Neural Network*

1. Introducción

La tecnología de la actualidad tiene un gran avance en cuanto a reconocimiento de imágenes, especialmente reconocimiento facial. Esto es mayormente usado para desbloquear ciertas funcionalidades de tu dispositivo móvil o para confirmar alguna acción financiera dentro de tu aplicación bancaria. Pero podemos ir más allá de solo mostrar nuestra cara y guardar los datos en algún dispositivo. Reconocer las distintas razas de perros mediante una imagen puede ser beneficioso para el ser humano, ya sea para saber que raza es algún perro por gusto propio, hasta para agilizar la publicación de alguna pérdida de mascota. No solo esto, si no que esperamos que en un futuro nosotros o alguien que use este artículo pueda desarrollar un modelo que no solo reconozca la raza, sino también otras cualidades como color, altura, peso y manchas únicas del perro para fines médicos. Este estudio tiene como objetivo realizar un modelo de inteligencia artificial funcional para los fines previamente mencionados.

2. Estado del Arte

A) Clasificador de razas de perros utilizando el modelo de inteligencia artificial Convolutional Neural Network

A continuación se muestran los pasos para seguir para el funcionamiento de nuestra CNN en cuanto al clasificador de razas de perros.

- Tenemos como input las distintas imágenes de perros con su respectiva raza como label.
- A través de multi-capas donde se van a extraer las distintas features del perro, se tratará llegar hasta un label. La extracción de características del animal nos sirven para categorizarlos según tamaño, color, forma de orejas, etc, para que el modelo sea posible de llegar a un label más certero.

- Una vez mostrado el label por el modelo, se comparará con el label correcto obtenido del dataset. De esta manera, tendremos un porcentaje de exactitud y a la vez podremos considerar algún cambio a los pesos o la extracción de features.
- Finalmente, después de horas de entrenamiento, el modelo será capaz de categorizar a los perros con mayor exactitud que cuando recién estaba siendo entrenado.




Figura 1: Source: Tabla de elaboración propia. Funcionamiento de nuestro modelo CNN

B) Método de diseño para el clasificador de perros utilizando CNN

Según [Lang, 2021] y [Norouzzadeh et al., 2018], CNN retorna resultados con un índice de error mínimo debido al funcionamiento de este. El primer autor habla de como esta es bastante eficiente el momento de reconocer ciertos items en una imagen.




Figura 2: Source: Heatmap representation of CNN [Le, 2018].

Como podemos observar en Figura 2, la convolución ocurre en cierta zona de la imagen dada como input a la red neuronal. De un área de 256x256 píxeles pasamos a tener que analizar simplemente 5x5. Esto se debe a que la red está entrenada para buscar el ítem deseado por el supervisor y después pasar por siguientes capas para tener un label como output. En la investigación realizada por [Lee et al., 2017], lograron usar CNN's para clasificación de más de

400,000 especies de plantas. El primer paso realizado fue entrenar al modelo de AI otorgándole raw data” de distintas plantas después de esto, se utiliza una DN (Deconvolutional Network) para observar cuales son las características en las cuales la CNN se basa para clasificar las plantas. De esta manera, les fue posible identificar por cuáles capas es que toda la data estaba pasando para obtener un output. Gracias a esta investigación hemos sido capaces de ver cómo es que una CNN puede identificar patrones y los distintos mapas de calor que genera. Si bien no vamos a usar una Deconvolutional Network, saber cómo funciona también es útil para nuestra investigación en caso algún día decidamos mejorar la precisión de nuestro indentificador automático de razas de perros.

C) Ethics in Image Recognition and AI models for classification

La ética en el reconocimiento de imágenes y los modelos de IA para la clasificación es un tema cada vez más relevante a medida que la tecnología avanza y se utiliza en una variedad de contextos. Aborda las cuestiones éticas que surgen cuando se utiliza la inteligencia artificial para la clasificación y el reconocimiento de imágenes, ya sea en seguridad, publicidad, medicina y más. A continuación, se explicarán algunas de las preocupaciones éticas clave en esta área.

Prejuicio y Discriminación: Uno de los principales problemas éticos con el reconocimiento de imágenes y los modelos de IA para la clasificación es el sesgo y la discriminación. Los algoritmos de IA se pueden entrenar con datos sesgados, lo que puede conducir a la discriminación y la exclusión. Por ejemplo, si un algoritmo de reconocimiento facial se entrena principalmente en imágenes de personas blancas, es posible que no sea tan preciso cuando se trata de reconocer rostros de personas de otras etnias. Esto puede tener graves consecuencias, como la exclusión de personas de grupos minoritarios en la sociedad. También existe el riesgo de que los algoritmos de IA se utilicen para el reconocimiento facial en contextos como la vigilancia, lo que podría aumentar el potencial de discriminación y control. Según [Morales Ramírez, 2023] una problemática al respecto es la aparente neutralidad de los algoritmos utilizados en su programación y su impacto a gran escala en relación con la discriminación generada a partir de los sesgos inmersos en ellos, provenientes de sus diseñadores. Esto quiere decir que algunas IA son discriminadoras debido a que sus desarrolladores lo son y por eso es importante seguir una serie de reglas al momento de desarrollarlas.

Privacidad: Otra cuestión ética importante en el reconocimiento de imágenes y los modelos de IA para la clasificación es la confidencialidad. Los datos de imágenes recopilados por los sistemas de IA pueden ser muy sensibles y se debe proteger la privacidad del usuario. Además, también existe el riesgo de que los datos puedan ser mal utilizados o compartidos con terceros sin el consentimiento del usuario, lo que podría comprometer su privacidad y seguridad. Según [Abad Molina and Arciniegas Castro, 2023] La era digital ha progresado desmesuradamente a lo largo del último siglo, dando paso a grandes avances como las nuevas inteligencias artificiales en el ámbito de la comunicación, las cuales han supuesto un nuevo paradigma en la recolección y almacenamiento de datos en la red, ocasionando conflictos en la preservación del derecho a la privacidad cibernética. Esto quiere decir que conforme avance el Big Data y mas información se tenga, siempre habrán datos que se filtren e invada la privacidad de algún usuario.

Responsabilidad y transparencia: También es importante considerar la responsabilidad y la transparencia en el uso de sistemas de reconocimiento de imágenes y modelos de IA para la clasificación. Las empresas y los desarrolladores deben ser responsables de las decisiones tomadas por sus sistemas de IA y ser transparentes sobre cómo funcionan y cómo se utilizan los datos de los usuarios. Esto es especialmente importante cuando se trata de sistemas utilizados en contextos críticos como la justicia penal.

D) Conclusiones

En conclusión, el campo de reconocimiento de imágenes y la clasificación de las mismas tienen ciertos problemas al ser aplicadas en el ser humano, es un terreno el cuál roza con los problemas sociales del racismo y el perfilado étnico. La tecnología actual no está lista para afrontar estos problemas de una manera justa para todos pero, en el caso de clasificación de especies de animales o de flores no hay necesidad de estos problemas sociales. Es más, la implementación de un buen modelo clasificador e identificador de estos organismos serviría para detectar más rápido ciertas carencias de estos. Enfermedades transmitidas o genéticas pueden ser detectadas de manera más rápida y eficiente con modelos de ai entrenados. El presente informe e investigación tiene como finalidad entender el funcionamiento

y desarrollar un modelo CNN (Convolutional Neural Network) para la clasificación e identificación automática de razas de perros, respetando los problemas éticos que esto puede tener y evitándolos para solo concentrarnos en el desarrollo del modelo.

Estudio Autodirigido

Aprendizaje profundo:

La página principal de Amazon Web Services define el aprendizaje profundo como un método de la inteligencia artificial (IA) que enseña a las computadoras a procesar datos de una manera que se inspira en el cerebro humano [Services, 2020]. Además, El aprendizaje profundo utiliza redes neuronales profundas para aprender patrones en los datos y construir modelos más precisos y complejos. Se utiliza retro-propagación para ajustar el modelo a los datos de entrenamiento mediante la actualización de los pesos de los nodos en cada capa. Esto permite realizar tareas complejas como reconocimiento de imágenes, procesamiento del lenguaje natural y toma de decisiones en situaciones complejas [Goodfellow et al., 2016]. Del mismo modo, el uso del aprendizaje profundo ha revolucionado el análisis de imágenes y ha permitido el desarrollo de aplicaciones como la clasificación automática de imágenes, la detección de objetos, la segmentación de imágenes y la super-resolución de imágenes [Zhang et al., 2019]. Entre los estudios más recientes, [Curioso and Brunette, 2020], mencionan que, en los campos de la medicina y la bioingeniería, el aprendizaje profundo ha sido aplicado en la clasificación de imágenes médicas, el diagnóstico de enfermedades, el diseño de prótesis y en la predicción de resultados clínicos. Del mismo modo, Kanakaraju y Sreedhar destacan la utilidad del aprendizaje profundo en el análisis de imágenes para la identificación de razas de perros, lo que puede tener importantes implicaciones en el diagnóstico y tratamiento veterinario. De lo previamente mencionado se colige que el aprendizaje profundo ayuda al entrenamiento de las redes neuronales convolucionales para determinar resultados basados en el análisis de imágenes.

Aprendizaje Automático:

De acuerdo con Google Cloud [Cloud, 2020], el aprendizaje automático forma parte de la inteligencia artificial y se basa en redes neuronales y aprendizaje profundo para permitir que un sistema mejore y aprenda por sí mismo. Esto se logra mediante la recopilación de grandes cantidades de datos y sin necesidad de programar el sistema de manera explícita. En la actualidad, han surgido muchos desafíos tecnológicos en los que el rendimiento del aprendizaje automático y las redes neuronales son impresionantes. En algunas áreas, la inteligencia artificial proporciona soluciones de última generación, especialmente en el reconocimiento visual y en el procesamiento del lenguaje natural. [Armenta, 2019]. Se proyecta que el mercado de reconocimiento de imágenes aumentará de 15.950 millones de dólares en 2016 a 38.920 millones de dólares en 2021, gracias a los progresos en el Aprendizaje Automático y el empleo de servicios con una mayor capacidad de procesamiento. Empresas de diversos sectores, incluyendo comercio electrónico, salud, automotriz y juegos, están adoptando rápidamente la tecnología de reconocimiento de imágenes [Martínez García, 2019].

Minería Web:

Según [Zhang et al., 2019], la minería web se utiliza para recopilar grandes cantidades de datos multimedia, incluyendo imágenes, videos y audio, de la web. Estos datos se pueden utilizar para entrenar modelos de aprendizaje automático en diversas aplicaciones, como la clasificación de imágenes, la detección de objetos y la recuperación de información multimedia. En adición, la minería web comprende tres procesos principales: la minería de contenido, que extrae información útil a partir de los contenidos de las páginas web y documentos web; la minería de estructura, que analiza la estructura de nodos y la conexión de un sitio web utilizando teoría de grafos; y la minería del uso de la web, que se encarga de extraer patrones e información de los registros del servidor para obtener conocimientos sobre la actividad del usuario, de dónde procede, cuántos usuarios han hecho clic en un elemento en el sitio y los tipos de actividades que se efectúan en el sitio [Senra, 2021]. Sobre lo anteriormente mencionado, en un estudio reciente, los autores utilizan una red neuronal convolucional pre-entrenada para extraer características de las imágenes de perros y entrenar un modelo de clasificación de varias clases en un conjunto de datos de imágenes de perros recopiladas de la web. El modelo alcanza una precisión de clasificación promedio del 87.08 % en un conjunto de datos de prueba de 120 razas de perros diferentes. Los autores destacan la importancia de la minería web para la obtención de datos y discuten los posibles desafíos en la implementación del enfoque en situaciones reales [Punyanuch Borwarnginn, 2021].

3. Aporte

En cuánto a la arquitectura elegida para el desarrollo del clasificador automático estaremos usando dos partes importantes, una convuitional neural network y una residual neural network. La primera, cómo ya hemos explicado en partes anteriores del informe, nos servirá para marcar un mapa de calor alrededor de la información la cuál nosotros queremos obtener. La segunda parte, la ResNet, nos permitirá aumentar el porcentaje de certeza, esto es por el funcionamiento de las ResNet. Estas, a diferencia de otras neural networks, consiguen el residuo de las funciones de las capas para que sigan siendo aplicadas en los demás inputs. La mayoría de métodos de inteligencias artificiales que funcionan con capas suelen tener non-nested function classes, ResNet se encarga de nestear estas funciones con el residuo de estas.




Figura 3: Source: [Zhang et al., 2023]

A) Datos de entrada

Para este clasificador automático tenemos como datos de entrada más de 20,000 imágenes de perros clasificadas en carpetas según su raza. El dataset utilizado es Standfor Dogs Dataset de Kaggle [Li, 2011]. Las imágenes de por sí no cuentan con el label para identificar su raza sino que, se utiliza la carpeta a la que estas pertenecen para poder saber la raza exacta del perro. Debido a que nuestro clasificador es un sistema supervisado, esta sería la manera en la cual tendríamos un output el cual comparar cada label y ver que tan cercana es la red neuronal a la raza del perro.

B) Tratamiento y normalización de datos

Kaggle es una plataforma web que cuenta con miles de datasets ya normalizados. Standford Dogs dataset ya ha sido tratado y normalizado para fines de estudio. Cada imagen está bien ubicada en su carpeta correspondiente. Debido a que estamos trabajando con un dataset normalizado no tenemos necesidad de pasar por este proceso.

C) Datos de salida

Para datos de salida se planea obtener el label de cada una de las imágenes presentadas en un "batch", este contiene las imágenes de 9 perros puestos en 3x3. Luego con la CNN vamos a conseguir el heatmap de estos para luego ser analizados por una ResNet y conseguir el label de cada uno. La manera en la que se presentará los datos será en un arreglo de esta manera: RazaDePerro", -azaDePerro", RazaDePerroz así por cada una de las 9 imágenes del batch. Este entrenamiento es más eficiente que estar recorriendo de manera individual las imágenes obtenidas del dataset. Después de esto ya podremos subir imágenes individuales y esperar que la neural network nos dé el label con alto porcentaje de certeza.


```
plt.figure(figsize=(10, 10))
for images, labels in train.take(1):
    for i in range(9):
        ax = plt.subplot(3, 3, i + 1)
        plt.imshow(images[i].numpy().astype("uint8"))
        plt.axis("off")
```



Figura 4: Source: Código e Imagen de elaboración propia. Batch de algunas imágenes de perros del Dataset

4. Diseño de la aplicación

Definiendo un diseño de la aplicación fue complicado para esta investigación y trabajo. He optado por la construcción del modelo dentro de un notebook de Kaggle para que la importación de modelos de entrenamiento y la importación de los datos sea más rápida y eficaz. La demostración del funcionamiento será vista por screenshots los cuáles serán explicados con un texto debajo para ayudar a la comprensión de la misma.

El funcionamiento de batches fue explicado en la sección anterior. Esta vez repasaremos por las librerías usadas para el funcionamiento de nuestro modelo.

```
[16]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import os

import tensorflow as tf
tf.config.run_functions_eagerly(True)
import tensorflow_hub as hub
from tensorflow.keras.models import Sequential, Model
from tensorflow.keras.layers import Dense, Input, InputLayer
from tensorflow.keras.callbacks import ModelCheckpoint, EarlyStopping

import warnings
warnings.filterwarnings("ignore")

plt.rcParams['font.size'] = 10
```

Figura 5: Source: Código e Imagen de elaboración propia. Librerías necesarias para el clasificador automático

Cabe recalcar que las librerías más importante son tensorflow y matplotlib. Tensorflow nos proporciona la CNN y matplotlib es importante para la creación del "batch".^a sí como también la creación de algunos gráficos para demostrar la certeza y el loss de cada época de nuestro modelo.

La siguiente parte importante para el desarrollo del modelo de AI para el clasificador automático de perros son las variables definidas como callbacksz .^e "Epochs".

Tres importantes callbacks para nuestro modelo de AI

ModelCheckpoint: Guarda el peso del modelo después de una "época" si la validación de pérdida mejora. EarlyStopping: Detiene el proceso de entrenamiento si la validación de pérdida no mejora después de un número de épocas. ReduceLROnPlateau: Monitorea una cantidad de datos de entrada y si no hay mejoras durante cierto número de épocas la tasa de aprendizaje disminuye

Estas 3 variables ayudarán a que el modelo no caiga en el rango de "Overfitting" y guarde el mejor modelo de acuerdo a la validación de pérdida.

```
7]: model_name = "model.h5"
checkpoint = tf.keras.callbacks.ModelCheckpoint(model_name,
                                                monitor="val_loss",
                                                mode="min",
                                                save_best_only = True,
                                                verbose=1)

earlystopping = tf.keras.callbacks.EarlyStopping(monitor='val_loss', min_delta = 0, patience = 5,
                                                  verbose = 1, restore_best_weights=True)

reduce_lr = tf.keras.callbacks.ReduceLROnPlateau(monitor='val_loss', factor=0.2,
                                                  patience=5, min_lr=0.0001)

history = model.fit(train, epochs=30, validation_data=val, callbacks=[checkpoint,earlystopping, reduce_lr])
```

Epoch 1/30
160/515 [=====>.....] - ETA: 46:04 - loss: 2.2112 - accuracy: 0.5021

(+ Code) (+ Markdown)

Figura 6: Source: Código e Imagen de elaboración propia. Variables callbacks y epoch

Dentro de la imagen y en el notebook tenemos la explicación de estas dos importantes partes del desarrollo del modelo. En la parte inferior tenemos en `.Estimated Time of Arrival`, el cuál indica que tanto tiempo estimado queda para que el modelo esté completamente listo para la clasificación. Cada epoch es definida como distintas agrupaciones de layers dónde los callbacks se encargan de cambiar la tasa de aprendizaje según la certeza o el resultado de pérdida.

5. Resultados y Discusión

Los resultados varían según el CPU y RAM de cada usuario que intente compilar las distintas partes del notebook, el entorno en el que estoy trabajando es local. Aún así con una memoria ram de 32Gb y un procesador i7-10750H CPU @ 2.60GHz ha tomado cerca de unas 4 horas en tener 30 épocas listas y cada una de estas teniendo 515 capas con las cuáles unas 20,000 imágenes iban a ser procesadas. Lo rescatabale de usar CNN y ResNet como modelos de clasificación sobre un sistema

```
history = model.fit(train, epochs=30, validation_data=val, callbacks=[checkpoint,earlystopping, reduce_lr])
```

Epoch 1/30
7/515 [.....] - ETA: 1:06:37 - loss: 7.0037 - accuracy: 0.0179

+ Code + Markdown

Figura 7: Source: Imagen de elaboración propia. ETA de primer epoch

supervisado es el alto porcentaje de certeza. Desde la primera época conseguimos un total de 0.6136 y en las siguientes solo ha ido aumentando hasta un aproximado de 0.70, estoy seguro de que con más epochs y modificando los callbacks podremos obtener mejor puntaje en este ámbito.

En los artículos mencionados como es el clasificador automático de plantas y detector de fauna silvestre en la naturaleza no usan ambos modelos para mejorar los resultados. En el primero el acierto llega a ser un aproximado de 60 % y en el segundo se logró obtener un 80 % pero tenían problemas al momento de detectar animales en la oscuridad o que tengan camuflaje. Para la representación de la pérdida hemos planteado un gráfico el cuál nos indica como esta ha ido bajando cada una de estas.



Figura 8: Source: Código y tabla de elaboración propia. Loss for each epoch made.

De igual manera, tenemos la representación de la certeza por cada época. Como podemos apreciar se ve una eficiente mejora, esto es gracias en su mayoría a los callbacks que nos ofrece ResNet50 v2.

Existe la posibilidad de que las epochs logren terminar si es que el modelo encuentra que las funciones utilizadas en las distintas capas no estén lo suficiente mejoradas para que se detenga el entrenamiento. En este caso tuvimos la buena suerte de que parase en la sexta época y nos de un porcentaje elevado de certeza



Figura 9: Source: Código y tabla de elaboración propia. Accuracy gain for each epoch.

Y por último, tenemos el porcentaje obtenido de certeza por nuestro modelo. Este es obtenido después de haber pasado por las correspondientes épocas del modelo. Los cuadros cambiarán según las distintas épocas que tengamos. Como ya mencionamos depende del callback que hayamos tenido para que estas funciones sobre cada capa paren debido al mejoramiento eficiente de estas.

```
loss, accuracy = model.evaluate(val)

129/129 [=====] - 10s 73ms/step - loss: 1.0861 - accuracy: 0.7097

print(f"Accuracy is: {round(accuracy*100,2)}%")

Accuracy is: 70.97%
```

Figura 10: Source: Código y tabla de elaboración propia. Total accuracy percentage.

Referencias

- [Abad Molina and Arciniegas Castro, 2023] Abad Molina, K. G. and Arciniegas Castro, C. L. (2023). La inteligencia artificial y la limitación al derecho a la privacidad cibernética, en estudiantes de jurisprudencia, cuenca-ecuador 2022: Artificial intelligence and the limitation of the right to cybernetic privacy, in students of jurisprudence, cuenca-ecuador 2022. *LATAM Revista Latinoamericana de Ciencias Sociales y Humanidades*, 4(1):657–666.
- [Armenta, 2019] Armenta, J. R. G. (2019). Clasificación de ladridos de perros domésticos usando aprendizaje profundo classification of domestic dog vocalizations using deep learning. *Gobierno de México*.
- [Cloud, 2020] Cloud, G. (2020). Google Cloud ¿qué es el aprendizaje automático?
- [Curioso and Brunette, 2020] Curioso, W. H. and Brunette, M. J. (2020). Artificial intelligence and innovation to optimize the tuberculosis diagnostic process. *Revista Peruana de Medicina Experimental y Salud Pública*, 37(3):554–8.
- [Goodfellow et al., 2016] Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press. <http://www.deeplearningbook.org>.
- [Lang, 2021] Lang, N. (2021). Using convolutional neural network for image classification. *Towards Data Science*.

- [Le, 2018] Le, J. (2018). The 4 convolutional neural network models that can classify your fashion images. *Towards Data Science*.
- [Lee et al., 2017] Lee, S. H., Chan, C. S., Mayo, S. J., and Remagnino, P. (2017). How deep learning extracts and learns leaf features for plant classification. *Pattern Recognition*, 71:1–13.
- [Li, 2011] Li, J. (2011). Stanford dogs dataset.
- [Martínez García, 2019] Martínez García, E. (2019). Clasificación de razas de perro mediante redes de neuronas convolucionales. *Universidad Carlos III de Madrid*.
- [Morales Ramírez, 2023] Morales Ramírez, G. (2023). Problemática antropológica detrás de la discriminación generada a partir de los algoritmos de la inteligencia artificial. *Medicina y Ética*, 34(2):429–480.
- [Norouzzadeh et al., 2018] Norouzzadeh, M. S., Nguyen, A., Kosmala, M., Swanson, A., Palmer, M. S., Packer, C., and Clune, J. (2018). Automatically identifying, counting, and describing wild animals in camera-trap images with deep learning. *Proceedings of the National Academy of Sciences*, 115(25):E5716–E5725.
- [Punyanuch Borwarnginn, 2021] Punyanuch Borwarnginn, Worapan Kusakunniran, S. K. . K. T. (2021). Knowing your dog breed: Identifying a dog breed with deep learning. *International Journal of Automation and Computing*, 18:45–54.
- [Senra, 2021] Senra, I. (2021). Aritmetics ¿qué es web mining?
- [Services, 2020] Services, A. W. (2020). Amazon Web Services ¿qué es el aprendizaje profundo?
- [Zhang et al., 2023] Zhang, A., Lipton, Z. C., Li, M., and Smola, A. J. (2023). Dive into deep learning.
- [Zhang et al., 2019] Zhang, W., Yao, T., Zhu, S., and Saddik, A. E. (2019). Deep learning-based multimedia analytics: A review. *ACM Trans. Multimedia Comput. Commun. Appl.*, 15(1s).